

专利技术交底书

一、发明名称	一种 SLO 自适应的 LLM 推理服务 Prefill-Decode 时分复用调度方法		
二、发明的相关记录数据			
完成时间	年 月 日	是否曾参考其它公开技术 ☐ 是(请务必填写第八项) ☐ 否	
开发档案	原开发的记录、说明或图式记载于编号第_____册至第_____册中，目前存放于_____		
三、发明人信息（重要信息，务必填写正确及完整）			
中文姓名		国籍	英文姓名
四、发明背景及已知技术说明			
请说明本发明的技术背景，解释本发明相应的已知技术，并指出该已知技术的缺陷。（需补充资料时，请另纸附上） 大语言模型（LLM）已经成为搜索、对话、代码辅助、文档处理等各类智能应用的核心底座，其在线推理服务承担着海量并发请求的处理任务。LLM 推理通常以请求为单位部署在 GPU/NPU 等 AI 加速卡上，并由推理引擎将多条请求进行批处理交由模型计算执行，而计算成本、吞吐与延迟是衡量推理服务效率的关键。在云服务侧，加速卡的资源开销构成 LLM 服务最主要的运行成本；而在许多推理部署场景中，可用的加速卡数量可能十分有限，因此单卡资源利用率的优化空间更加直接决定服务可承载的并发的规模。 LLM 主流采用 Transformer 架构与自回归生成方式，每个请求的推理过程被自然划分为两个计算特性截然不同的阶段：预填充（Prefill）和解码（Decode）阶段。Prefill 阶段一次性处理用户输入的完整提示词（Prompt）序列，并行执行注意力与前向计算，生成第一个输出词元（Token）并将中间结果写入键值缓存（KV Cache）。该阶段的并行度主要取决于提示词的长度，其单次计算的算子规模较大、对加速卡的算力需求高，但是访存次数较少，属于典型的“计算密集型”。Decode 阶段基于已有的 KV Cache 逐个 Token 地生成输出，每次迭代只输出一个新的 Token，但需要反复读取整个 KV Cache 用以注意力计算。该阶段单次的计算量较小、并行度低，但是显存带宽占用高，属于典型的“访存密集型”。两个阶段对算力与存储带宽资源的需求天			

然互补：当系统中正在执行的请求都处于 Prefill 阶段时，算力会被大量占用而显存带宽相对空闲；而当请求都处于 Decode 阶段时，显存带宽则被大量占用算力资源相对空闲，因此如何更好地调度两个阶段的资源是单卡推理服务效率优化的核心。

LLM 推理服务的性能评估通常围绕以下指标展开：首 Token 生成时间（TTFT，Time-To-First-Token）、每 Token 生成时间（TPOT/TBT，Time-Per-Output-Token/Time-Between-Tokens）、端到端延迟和吞吐量。TTFT 描述用户提交请求到收到第一个输出 Token 的延迟，主要由请求排队时间与 Prefill 阶段执行时间决定，反映系统对新到请求的响应能力；TPOT/TBT 用来描述每两个相邻输出 Token 之间的延迟，主要由 Decode 阶段每次迭代的执行时间决定，反映正在处理的请求的输出频率是否稳定；端到端延迟与吞吐量则刻画整体的响应时间与服务承载能力。在交互式应用中，TTFT 与 TPOT 是关键的服务基本目标（SLO，Service Level Objective），而在批处理类应用中，吞吐量通常是首要目标。在真实的推理服务场景中，调度器通常需要在严格的 TTFT 与 TPOT 的 SLO 约束下追求系统的有效吞吐量（Goodput，即在满足 SLO 前提下的请求吞吐量）的最大化，这构成了 LLM 推理服务调度度的核心问题。

在上述 P/D 两阶段资源需求互补与 SLO 约束的共同作用下，如何在推理系统中协调 Prefill 与 Decode 两个阶段的执行，成为了 LLM 推理服务系统近年来最活跃的研究方向之一。现代 LLM 推理引擎（如 vLLM、SGLang 等）普遍以迭代级（Iteration-level）调度为核心范式：调度器以一次推理迭代为基本单位组织批处理、调用模型执行，并通过连续批处理（Continuous Batching）与 PagedAttention 等技术去支撑高并发下的请求处理与 KV Cache 管理；

围绕上述 P/D 协同调度问题，业界沿不同技术路径发展出三类主要的方案。

第一类是 PD 耦合架构，Prefill 与 Decode 共享同一资源，在同一个批次中混合处理。早期的 PD 耦合方式不对 Prefill 和 Decode 做区分，而是将所有请求都统一放到一个批次中执行，虽然实现简单但长 Prompt 的 Prefill 阶段会潜在影响同一批次中 Decode 请求的输出延迟。为了缓解这一问题，有研究提出了 Chunked Prefill 技术，其将一个较长的 Prefill 阶段切分为较小的 Chunk 块之后，再与 Decode 请求混合在同一个批次中执行，通过调节分块大小来调整 P/D 阶段的干扰。Chunked Prefill 技术是当前耦合架构下非常成熟的优化技术，已内置于 vLLM 等主流的推理引擎中。

第二类是 PD 分离架构，其将 Prefill 与 Decode 分置到不同的实例上独立执行，通过高速互联在阶段间传输 KV Cache，从物理上消除阶段间干扰，是当前大规模部署场景下的主流选择。然而该方案需要至少两张加速卡并需要承担 KV Cache 跨卡迁移开销，在资源受限的部署场景下性能受限。

第三类是 PD 动态混部，在同一张加速卡内更具负载特征动态协调 P/D 两阶段的执行，以进一步地提升 Goodput。动态混部主要存在两条技术路径：空分复用和时分复用。其中，空分复用依托硬件细粒度计算单元的切分能力(如 GPU 上的 MPS、GreenContext 等)，让 Prefill 和 Decode 同时调度到同一张卡上的不同计算单元上执行；而时分复用则是让 Prefill 与 Decode 在同一物理资源上交替独占执行，利用两阶段在算力与带宽需求上互补来提升资源利用效率。

综上，上述三类方案探索了 PD 协同调度的可行路径，其共同目标均为最大化推理服务的有效吞吐量（Goodput），但都仍存在以下几个问题：

（1）现有 PD 耦合/分离架构存在不可消除的结构性代价，在真实动态负载下难以最大化 Goodput：

真实 LLM 在线推理负载在并发规模、Prompt 长度、请求到达模式等维度上持续波动，P/D 两阶段对算力与访存带宽的需求随之不断变化，协调 P/D 两阶段执行成为最大化 Goodput 的核心矛盾。现有两大类标准部署方案各自存在不可消除的结构性代价：PD 耦合架构将 P/D 置于同一批次中共享资源，同一批次内 Prefill 计算会导致 Decode 请求的 TPOT 增加，两阶段相互干扰难以同时满足 TTFT 与 TPOT 要求；该架构虽发展出 Chunked Prefill 等动态机制，但其“混合批处理”的基础形态决定了 P/D 阶段间干扰无法从根本上消除。PD 分离架构通过跨实例部署 P/D 从物理上消除干扰，但 Prefill 与 Decode 分别在不同物理资源上执行，阶段切换时须承担 KV Cache 跨实例迁移开销。两类架构的代价分别源于其基础执行形态，在真实波动负载下均使 Goodput 存在明显瓶颈。

（2）现有 PD 动态混部方案未能兼顾硬件普适性与真是动态负载下的调度灵活性，难以最大化 Goodput：

PD 动态混部的空分复用与时分复用是两条在资源利用模型上本质不同的路径，空分复用路径依

托于硬件细粒度计算单元切分能力（如 MPS、GreenContext 等），其调度机制可在迭代粒度上根据负载动态调整分区比例，具备较好的调度灵活性；然而该路径的全部创新均依附于上述硬件能力，在不具备成熟空分复用能力的加速器上无法应用。时分复用路径让 P/D 在同一物理资源上交替独占执行，无需任何分区硬件抽象，在硬件普适性上具有独特优势；然而时分复用的阶段互斥性使得每一次迭代粒度的阶段决策都瞬时影响执行中 Decode 请求的 TPOT 与新到请求的 TTFT，对调度机制的负载感知能力提出了更高要求，而现有时分复用方案多采用固定 P/D 时间分片比例或启发式策略安排 P/D 交替，并且缺乏细粒度的 SLO 反馈机制，在真实动态负载下对 P/D 执行比例的调节比较粗略。两条路径各有所长但各有所缺，现有 PD 动态混部方案中尚无一种方法能同时实现硬件普适性与迭代粒度的负载感知调度，难以在通用加速器上最大化 Goodput。

综上，本发明针对上述两个问题，提出一种基于时分复用的 Prefill-Decode 动态调度方法。该方法以 SLO 自适应控制模块为核心，通过滑动时间窗口内的 SLO 余量反馈在迭代粒度上自适应调节 P/D 执行比例，并以分层状态采集模块为其提供低开销的硬件状态输入，共同实现迭代粒度的负载感知调度；同时，为使该方法在采用预编译计算图的加速器上高效落地，配套设计图识别控制模块，将预编译计算图的形状（shape）约束纳入批次组织决策，减少填充（padding）浪费，从而在通用加速器上同时实现硬件普适性与迭代粒度的负载感知调度。

五、技术内容揭露

请说明本发明之创作特征，并从不同角度（如结构、功能、制程、成本等）解释本发明之进步性。若为软件发明，请提供相关数据流程图、方块图等，并对照流程图进行说明。请说明本发明相对于已知技术之进步性，并介绍本发明是如何克服已知技术缺陷并实现其优点。（需补充资料时，请另纸附上）

1. 发明点描述：

本发明提出了一种 SLO 自适应的 LLM 推理服务 Prefill-Decode 时分复用调度方法。针对现有 PD 耦合架构存在 P/D 阶段间相互干扰、PD 分离架构存在 KV Cache 跨物理资源迁移开销、两者均存在不可消除的结构性代价、在真实动态负载下均使 Goodput 存在明显瓶颈的问题，以及现有 PD 动态混部方案未能兼顾硬件普适性与真实动态负载下的调度灵活性的问题，本发明采用时分复用路径，在同一加速卡上通过时间维度交替执行 Prefill 与 Decode，并根据负载动态特征在迭代粒度上自适应调节两者的执行比例；整体方案不依赖于 MPS、GreenContext 等空间分区硬件抽象，适用于任何支持预编译计算图的加速器。

该方法采用的系统架构，主要由三个相互配合的模块组成。SLO 自适应控制模块根据 SLO 余量与待处理请求数等实时负载指标，基于闭环反馈机制在迭代粒度上动态调节 P/D 执行比例，使其持续逼近当前负载下的 Goodput 最优。图识别控制模块根据当前执行模式、预编译计算图的形状集合确定具体批处理大小，将相关建议反馈给 SLO 自适应控制模块。状态采集模块通过离线与在线采样相结合的方式，向上述两个模块提供延迟、利用率等硬件状态信息。


2. 发明目的：

本发明的目的在于：提供一种基于时分复用的 Prefill-Decode 动态调度方法，使 P/D 在同一加速卡上按时间维度交替执行，从根本上避免现有耦合与分离架构各自存在的结构性代价；使该方法能够在迭代粒度上随真实动态负载实时调节 P/D 执行比例，以持续逼近当前负载下的 Goodput 最优，弥补现有动态混部方案在硬件普适性与调度灵活性上难以兼顾的不足；并配套解决该方法在采用预编译计算图的加速器上的高效落地问题，使其具备广泛的加速器适用性与工程可落地性。

3. 实施方案：

本发明提供了一种 SLO 自适应的 LLM 推理服务 Prefill-Decode 时分复用调度方法，其整体框架如下：

3.1 整体架构图：



3.2 模块及各个模块功能：

包括有 SLO 自适应控制模块、图识别控制模块和状态采集模块，每个模块实现特定的功能，以实现 LLM 推理系统的 Goodput 最大化，以下是各个分级模块的功能介绍：

3.2.1 SLO 自适应控制模块

SLO 自适应控制模块运行在推理服务的调度器中，是本系统的核心决策模块。该模块的运行同时横跨两个时间尺度：在迭代尺度上做出每次迭代的执行决策，在滑动时间窗口尺度上对决策所依据的控制参数进行反馈调节；两者协同实现“个例决策即时响应、整体比例平滑收敛”的效果。在迭代尺度上，模块于每次迭代开始时读取系统当前运行状态，包括等待请求队列深度、正处理的 Decode 的请求数、队首请求距 TTFT 约束的剩余余量、Decode 请求中最紧迫的 TPOT 余量，以及由状态采集模块提供的硬件利用率、由图识别控制模块提供的批次组织优化建议；据此先检查防饿死硬约束以保证两阶段请求在极端负载下均不被无限延迟，再依据当前 P/D 执行比例参数决定本次迭代的执行模式——Prefill 或 Decode——并结合图识别建议确定具体的批次组成。在滑动时间窗口尺度上，模块以 SLO 达成情况为反馈信号对上述 P/D 执行比例参数进行闭环调节：若窗口内出现 SLO 违约，则向降低 Prefill 频率的方向调节以优先保护 Decode

延迟；若窗口内 SLO 全部达成且仍有待处理请求，则向提升 Prefill 频率的方向调节以扩大新请求接纳能力；调节过程遵循平滑原则，避免波动负载下的震荡与滞后。由此，每次迭代的即时决策都建立在一个随负载持续演化的比例基准之上。

主要功能：在迭代尺度上做出执行模式与批次组成的即时决策，在滑动窗口尺度上基于 SLO 达成情况对 P/D 执行比例参数进行闭环反馈调节。

作用：使 P/D 执行比例与真实动态负载持续对齐，逼近 Goodput 最优。

3.2.2 图识别控制模块：

图识别控制模块作为第一层的优化建议提供方而存在，不直接对执行引擎下达指令，而是将底层预编译计算图的形状约束抽象为结构化建议交由第一层在做决策时一并考虑。该模块以当前等待请求队列与运行中请求集合的规模信息、底层执行引擎所支持的预编译计算图形状集合，以及由状态采集模块提供的各已编译形状下的执行延迟与资源利用率画像为输入；其输出为一组可供第一层查询的批次组织优化建议，例如“当前队列规模已在某已编译形状下可精确匹配、建议切换到 Prefill”，或“若立即按当前模式组批将发生较大形状失配、建议延后若干迭代再切换”。此外，该模块利用状态采集模块提供的硬件画像量化各候选形状下的执行代价与填充浪费，在此基础上为当前队列择优匹配，识别形状失配风险较高的时点与形状对齐收益较高的时点，并据此生成建议。具体建议是否被采纳由第一层综合 SLO 余量与其它状态后决定，从而避免与第一层职能的耦合与重叠。

主要功能：基于队列状态与预编译计算图形状集合生成批次组织优化建议，供第一层决策时参考。

作用：将底层预编译计算图的形状约束以建议形式注入调度闭环，提升形状命中率、减少填充浪费与非预编译执行路径的回退，而不对第一层决策形成刚性干预。

3.2.3 状态采集模块：

状态采集模块为上述两层提供硬件状态输入。考虑到持续高频采样会与推理计算争抢带宽并显

著折损吞吐，本模块采用“离线画像+在线低频采样”的分层设计：以针对动态负载进行不同批次大小和 PD 调度等信息的离线采样作为基础参考，以运行时的实时硬件状态作为在线补充，然后向 SLO 自适应控制模块与图识别控制模块输出执行延迟估计、算力利用率与带宽利用率等硬件状态信息。其中，离线采样会在部署前一次性生成，运行时以查表方式直接获取相关信息；实时算力利用率由运行期低频异步采样获取，作为 SLO 自适应控制模块反馈调节的辅助信号；对采样代价较高的带宽利用率等指标，默认走离线查表，仅在阶段切换等关键时点做少量在线校正。

主要功能：以分层方式提供硬件状态信息。

作用：使上层决策具备硬件感知能力，在不损害吞吐的前提下为闭环反馈与批次组织提供可靠依据。

4. 如何克服缺点：

相比于现有 LLM 推理服务调度方案，本发明做出以下改进：一方面，采用时分复用路径在同一加速卡上交替执行 Prefill 与 Decode，P/D 不再共享同一个批次进行处理，从根本上消除耦合架构下的阶段干扰；同时 P/D 在同一物理资源上交替执行，阶段切换时复用同一份模型权重与 KV Cache，避免分离架构下的 KV Cache 跨资源迁移开销。另一方面，在时分复用的基础上，通过 SLO 自适应控制模块以滑动窗口内的 SLO 达成情况为反馈信号、在迭代粒度上平滑调节 P/D 执行比例，克服现有时分方案调节偏粗的问题；并通过图识别控制模块与状态采集模块将预编译计算图约束与硬件状态纳入调度闭环，使整体方案不依赖任何空间分区硬件抽象，在通用加速器上同时获得硬件普适性与迭代粒度的负载感知调度能力。

六、检测和实验验证

如有相关检测或实验验证，请列出本发明已进行的检测和实验验证（并附送相关文件）。

七、应用领域

请列举本发明已知和潜在的技术/产品应用领域及其应用方式。（需补充资料时，请另纸附上）
（1）用户侧：本发明可应用于聊天机器人、代码助手、智能客服等对 TTFT 与 TPOT 有严格 SLO 要求的交互式 LLM 应用场景，通过 P/D 时分复用动态调度，在负载波动时将用户侧的响应延迟维持在 SLO 范围内。

(2) 资源集群侧：本发明可作为通用加速器上 LLM 推理服务的调度策略，尤其适用于不具备空分复用能力的加速器以及边缘端侧等部署场景。该方法可集成到主流 LLM 推理框架（如 vLLM）以及云服务推理平台中，对模型层与推理引擎无侵入，在保证 SLO 的前提下提升单卡有效吞吐量、降低单位推理成本。

八、已公开的信息

有下列情形之一的，请说明具体情况，并附上相关材料：（一）在中国政府主办或者承认的国际展览会上首次展出的；（二）在规定的学术会议或者技术会议上首次发表的；（三）他人未经申请人同意而泄露其内容的。

九、引证资料

除专利申请表中所列之附件外，请列出与本发明相关之参考资料及文献，如学术报告、论文、技术报告等，并请附送复印件。（需补充资料时，请另纸附上）

十、其它说明

除以上数据外，如有其它相关信息，请加以说明。